Module MLBDA Master Informatique Spécialité DAC

COURS 7 - XQUERY

Plan

Concepts des langages de requêtes XML

- Motivations
- Caractéristiques

XQuery

Exemples de requêtes

Manipulation de données XML

Document XML

- Structure flexible pas toujours connue à l'avance
- Peut varier selon les documents

Applications XML

- Formats de données standards
 - MathML, SVG, GeoML, RDF, ...
- Echange de données
 - Tables, XLS, CSV → documents XML → Tables, XSL, CSV
- Transformation de données
- Stockage, intégration et interrogation de données
 - Bases de données XML
 - XQuery

Interroger des données XML

Bases de données XML

- Collection de documents XML
- Importation et exportation de documents
- Interrogation des collections : Xpath / XQuery
- Optimisation, indexation, ...

Interroger des documents XML

- XPath : sélectionner des fragments XML dans un document
- XPath est insuffisant pour interroger des collections
 - Interroger plusieurs documents à la fois
 - Combiner des fragments
 - Créer des nouveaux documents / fragments

Besoin d'interroger des données XML

Besoins pour la Recherche d'Information (RI) et les bases de données (SGBD).

XML pour la RI

- Recherche « full text » et par contexte
- Indexation

XML pour les SGBD

- Interroger la structure complexe des données
- Construire une structure complexe
- Langage déclaratif : expressivité, optimisation, ...



Requête XML = SQL + RI + Navigation

Expressivité du langage de requêtes

Requête déclarative: pattern + filtre + constructeur

Extraction / filtrage de fragments dans des documents

Navigation dans un arbre → XPath

Combiner des ensembles de fragments :

- Logiques: and, or, négation, quantification
- Ensembles / listes : union, différence, concaténation, tri
- Algébriques : jointure, projection

Construire des nouveaux fragments :

- Créer une nouvelle structure d'arbre
- Imbrication: ajouter des niveaux

Types et fonctions :

- Agrégation : somme, moyenne,
- Comparaison de chaînes de caractères, etc.

Spécification des besoins: Use Cases (W3C)

Use Case « XMP »: Experiences and Exemplars

Autres USE CASES:

- TREE : requêtes préservant la hiérarchie
- SEQ : requêtes basée sur des séquences
- R : accès à des données relationnelles
- SGML: standard generalized markup language
- TEXT : recherche full-text
- NS: requêtes avec des espaces de noms (namespaces)
- PARTS : recursive parts explosion
- REF : requêtes utilisant des références
- FNPARM : requêtes avec fonctions et paramètres

DTD bib.dtd

```
<!ELEMENT bib (book*)>
<!ELEMENT book (title, (author+| editor+), publisher, price)>
<!ATTLIST book year CDATA #REQUIRED>
<!ELEMENT author (last, first)>
<!ELEMENT editor (last, first, affiliation )>
<!ELEMENT title (#PCDATA )>
<!ELEMENT last (#PCDATA )>
<!ELEMENT first (#PCDATA )>
<!ELEMENT affiliation (#PCDATA )>
<!ELEMENT publisher (#PCDATA )>
<!ELEMENT price (#PCDATA )>
```

Document bib.xml

```
<bib>
                                                                 <book year="2000">
   <book year="1994">
                                                                       <title>Data on the Web</title>
     <title>TCP/IP Illustrated</title>
                                                                       <author><last>Abiteboul</last><first>Serge</first></author>
     <author><last>Stevens</last><first>W.</first></author>
                                                                       <author><last>Buneman</last><first>Peter</first></author>
     <publisher>Addison-Wesley</publisher>
                                                                       <author><last>Suciu</last><first>Dan</first></author>
     <price> 65.95</price>
                                                                       <publisher>Morgan Kaufmann Publishers/publisher>
   </book>
                                                                       <price> 39.95</price>
   <book year="1992">
                                                                     </book>
     <title>Advanced Programming in Unix</itle>
                                                                  <book year="1999">
     <author><last>Stevens</last><first>W.</first></author>
                                                                      <title>The Economics of Technology and Content for TV</title>
     <publisher>Addison-Wesley</publisher>
                                                                       <editor>
                                                                           <last>Gerbarg</last><first>Darcy</first>
     <price>65.95</price>
   </book>
                                                                           <affiliation>CITI</affiliation>
   <book year="1994">
                                                                       </editor>
     <title>Database theory</title>
                                                                       <publisher>Kluwer Academic Publishers/publisher>
     <author><last>Abiteboul</last><first>Serge</first></author>
                                                                       <price>129.95</price>
     <author><last>Hull</last><first>Rick</first></author>
                                                                  </book>
     <author><last>Vianu</last><first>Victor</first></author>
                                                                </bib>
   </book>
```

Qu'est-ce qu'on veut faire avec des requêtes ?(1)

Sélection et extraction :

- tous les couples (\$titre, \$auteur) des ouvrages publiés par Eyrolles depuis 2000
- l'arbre XML de la base est « mis à plat » : séquence de (\$titre, \$auteur)

Reconstruction d'arbres XML:

- générer un arbre respectant la DTD originale
- réorganiser la structure par rapport à une DTD nouvelle : livres par auteur
 - <!ELEMENT author (book+)>
 - <!ELEMENT book (title, author+,publisher?, price?)>

Combiner plusieurs sources de données :

 joindre la base des livres et celle des adresses pour avoir les livres et les adresses des auteurs et éditeurs.

Trier les résultats :

titre des livres par ordre alphabétique

Qu'est-ce qu'on veut faire avec des requêtes ?(2)

Indexer les éléments de la structure :

 lister les livres par leur titre et les deux premiers auteurs (et un élément et al s'il y a plus que deux auteurs)

Filtres d'extraction ensemblistes :

extraire pour chaque livre tous les enfants sauf le prix

Accès approximatif par le contenu (« plein texte »):

 retrouver les sections ou les chapitres traitant de bases de données (indépendamment du niveau d'imbrication)

XQuery

Spécification du W3C (v1.0, oct.2004 \rightarrow v. 3.1 mars 2017)

- inspiré de SQL
- satisfait les requêtes des Use Cases
- construit au-dessus de Xpath

XQuery est un langage fonctionnelle sur des séquences :

- valeur XQuery:
 - séquence de fragments/noeuds XML et de valeurs (entiers, chaîne des caractères,)
- expression XQuery :
 - composition de fonctions sur des séquences
 - retourne une valeur ou une erreur
 - pas d'effets de bord
 - fonctions utilisateurs (Turing Complet)

Expressions XQuery

expressions simples

expressions de chemins

comparaisons

construction d'éléments

expressions FLWOR

conditions

quantificateurs

types de données

Modèle de données Xquery (XDM) : items et valeurs

Items:

- Types XML Schema: entier, string, booléen, date, XML
- valeurs atomiques: 32, "coucou", true(), false(), integer("12"), date ("01/01/2017")
- fragments / nœuds XML: vre><auteur>Ullman</auteur>

Opérateurs items:

- logiques : and, or, not
- arithmétiques : +, -, *, div, mod
- comparaison de valeurs : eq, lt, gt
- comparaison de position : is, <<, >>

Fonctions: contains(), substring(), abs()...

Valeurs:

- séquence d'items
- (10, 1, 2, 3, 4)
- (3,false(),true())
- (1, "toto", <toto/>, <a>1</a)</p>
- Séquence vide: ()

Opérateurs séquences:

- concaténation:
- union: union
- différence : except
- intersection : intersect
- o comparaison : =, <, >, !=, <=, >=

Fonctions: count(), last(), first()...

Expressions XQuery

Expressions simples:

- items et variables
- « 32 » est une expression qui retourne la valeur 32
- \circ « 32 » \rightarrow 32
- \$a, \$book, \$x : variables affectés à une valeur (séquence)

Expression sur les séquences :

- séquence d'expressions qui retourne une valeur (séquence)
- → requête XQuery

L'opérateur de concaténation « , » évalue chacune des expressions et la remplace par la séquence résultat dans l'ordre.

Résultat : une séquence d'items

- \circ « (10, (1, 2), 3, 4) » \rightarrow (10, 1, 2, 3, 4)
- \circ « (1+2, 2=3, 3>2) » \rightarrow (3, false(), true())
- « (<a>1+2) » → (<a>1+2)
- \circ « 47 » \rightarrow (47)

Autres opérateurs:

- \circ « (10, 1, 2, 3, 4) except (1+1) » \rightarrow (10, 1, 3, 4)
- « (10, (1,2), ()) union (3,(4)) » \rightarrow (10,1,2,3,4)
- « (1+2, 2+3, 3*2) intersect $(4) \gg \rightarrow ()$
- « (1+2, 2=3, 3>2) intersect (true()) » → (true())

Expressions de chemin

Ex : document("bib.xml")//book//author[nom="martin"]

séquences des éléments de type author avec le nom 'martin'

XPath sert à extraire des séquences de fragments / nœuds XML à partir de documents ou d'autres fragments.

- bib/book[last()] → séquence de nœuds book
- ./child::author[position() >1] → séquence de nœuds author
- //book[@year= "2002"]/author/last → séquence de nœuds last

Le contexte d'une expression Xpath est:

- Un document XML: document("bib.xml")//book/author
- Une collection de documents XML : collection("archive")//book/author
- Une variable: \$alice/last
- Défini par défaut : //book/author

Expressions de chemin et opérateurs de séquences

Comparaisons d'items

Les opérateurs **eq**, **ne**, **lt**, **le**, **gt**, **ge** permettent de comparer des **item** :

- \$book1/title eq 'Data on the Web' → true() ssi \$book1 a exactement un élément fils title dont la valeur est la chaîne "Data on the Web"
- \$book1/price gt 100 → true() ssi il y a un seul prix et sa valeur est > 100
- 1 eq 1 → true(), 1 eq 3 → false(), 1 eq (2) → false(), (1+1) eq (2) → true(),
- \circ (1,2) eq (3) \rightarrow erreur

Comparaisons de noeuds XML

Les nœuds (éléments) sont comparés par leur valeur textuelle:

• <last>Bob</last> eq <first>Bob</first> → true()

Utiliser la fonction deep-equal pour comparer la structure et la valeur:

```
deep-equal((<a><b>1</b></a>),(<a>1</a>))→ false()
```

```
deep-equal((<a>1</a>),(<a>1</a>))→ true()
```

Comparaisons de nœuds XML

Les opérateurs is, <<, >> permettent de comparer deux nœuds, par leur identité et par leur ordre dans le document

Si l'une des opérandes est la séquence vide, le résultat est une séquence vide.

is renvoie true() si s'il s'agit du même nœud à gauche et à droite;

- < <a>5 is <a>5 » \rightarrow false()
- « //book[year= "2002"] is //book[title= "Data on the Web"] » → true() si
 Data on the Web est le seul livre de 2002

<< (resp. >>) renvoie true() si le nœud de gauche précède (resp. succède) le nœud de droite dans l'ordre du document:

« //produits[ref="123"] << //produits[ref="456"] » → true() si le produit 123 est avant le produit 456 dans le document.

Comparaisons de valeurs (séquences)

Les opérateurs =, !=, <, >, <=, >= permettent de comparer des séquences d'items (valeurs).

S op S' retourne true() s'il existe un item i dans S et un item i' dans S' tels que i op i' est vrai.

Exemples:

Construction d'éléments

Il est possible de construire des éléments à l'intérieur des requêtes, soit directement en XML, soit en utilisant des expressions Xquery. Crée un nouvel élément book, avec un titre et un auteur, un nom et un prenom.

Requête:

```
<book isbn="isbn-1234567890">
    <titre>100 ans de solitude</titre>|
    <auteur>
        <prenom>Gabriel</prenom>
        <nom>Garcia Marquez</nom>
        </auteur>
    </book>
```

Résultat:

Construction d'éléments

Insertion de résultats d'expressions XQuery avec { <exp> }

```
$b:
<book isbn="isbn-1234567890">
     <titre>100 ans de solitude</titre>
</book>
                                      Résultat:
Requête:
                                        En vacances, j'ai lu :
 En vacances, j'ai lu :
                                        <req>
  <req>
                                           <titre>100 ans de solitude</titre>
     { $b/titre }
                                        </req>
  </req>
```

Construction d'éléments

On peut aussi construire des éléments et des attributs de la façon suivante :

Le **nom** et le contenu des éléments et des attributs peuvent être calculés par des expressions.

Expression FLWOR

for – let – where - order by - return

```
Exemple : personnes ayant édité plus de 100 livres

for $p in document("bib.xml")//publisher

let $b:=document("bib.xml")//book[publisher = $p]

where count($b) > 100

return $p
```

- for itère sur une liste ordonnée d'éléments publisher désignée par \$p
- let affecte une séquence d'éléments book à la variable \$b
- where filtre les couples (\$p,\$b) où \$b contient plus que 100 éléments (livres)
- return construit pour chaque couple la valeur résultat.

Résultat final : séquence d'éléments publisher

for et let : Affectation de variables

-for \$var in <exp>

• Itération sur les items de la séquence générée par <exp> et, à chaque itération, affectation à la variable \$var de l'item courant (boucle)

-let \$var:= <exp>

Affecte à la variable \$var de la séquence générée par <exp>

Les clauses **for** et **let** peuvent contenir plusieurs variables, et peuvent apparaître plusieurs fois dans une requête (utile pour la jointure).

Exemples

```
let $s := (<un/>, <deux/>, <trois/>)
return <out>{$s}</out>
```

Résultat : séquence avec un élément

out:

```
for $s in (<un/>, <deux/>, <trois/>)
return <out>{$s}</out>
```

Résultat : séquence de **trois** éléments out:

```
<out> <un/> </out> ,
 <out> <deux/> </out> ,
 <out> <trois/> </out>
```

where: applications de filtres

where <exp> : permet de filtrer le résultat par rapport au résultat booléen de <exp>

for \$x in document("bib.xml")//book where \$x/author/last = " Ullman " return \$x/title

Renvoie la sequence des titres des livres dont Ullman est auteur

return: construction du résultat

La clause **return** est évaluée une fois pour chaque itération et le résultat est une séquence d'items.

L'ordre est déterminé par l'ordre du documents XML et les clauses for et let. for \$e in document("doc.xml")//employees
return (\$e/first, \$e/last)

→ séquence qui alterne les éléments first et last dans l'ordre du document

for \$e in document("doc.xml")//employees
return \$e/first, \$e/last

- → le résultat est une séquence d'éléments first suivi du résultat de l'expression \$e/last
- → Erreur : la variable \$e n'est pas liée

order by et return: tri

La clause **order by** permet de réordonner les n-uplets dans l'ordre croissant (**ascending**) et décroissant (**descending**).

for \$e in
document("doc.xml")//employees
order by \$e/salary descending
return \$e/name

→ séquence avec un élément name pour chaque employé

for \$b in document('bib.xml")//book
order by \$b/price, b/title
return \$b

→ séquence d'éléments book triés par le prix et le titre.

if-then-else: construction conditionnelle

Produire des résultats « conditionnelles »:

some et exists : quantificateurs existentielles et universelles

some \$x in <expr1> satisfies <expr2> → true() s'il existe AU MOINS UN nœud dans la séquence renvoyée par <expr1> qui satisfait <expr2>

some \$b in document("bib.xml")//book satisfies \$b/@year >2003

→ true() si au moins un livre a un attribut dont la valeur est supérieure à 2003.

every \$x in <expr1> satisfies <expr2> → true() si TOUS les nœuds dans la séquence renvoyée par <expr1> satisfont <expr2>

every \$b in document("bib.xml")//book satisfies \$b/@year

→ true() si tous les livres ont un attribut year.

Exemple

On suppose qu'un élément book contient plusieurs éléments resume: for \$b in document("bib.xml")//book where some \$p in \$b//resume satisfies (contains(\$p, "sailing") and contains(\$p, "windsurfing")) return \$b/title

→ titre des livres mentionnant à la fois sailing et windsurfing dans le même élément resume.

for \$b in document("bib.xml")//book
where every \$e in \$b//editor satisfies \$e/affiliation='LIP6'
return \$b/title

→ titre des livres dont tous les éditeurs sont affiliés au LIP6.

Types

XQuery supporte les types de données de XML Schema, types simples et complexes.

<item> instance of <type> → true() si la valeur du premier opérande est du type du deuxième opérande:

```
3 instance of xs:integer → true() <x>3</x> instance of element() → true()
```

typeswitch .. cause ..default ..: branchement en fonction du type

```
typeswitch($e)
case $e as element(book) return $e/editor
case $e as element(author) return $e/last
default return ()
```

cast : « forcer » un type:

xs:date("2000-01-01")

Exemple (1)

```
Livres publiés par Addison-Wesley depuis
1991, avec l'année et le titre
<bi>hib>
                                               <bib>
{ for $b in document("www.bn.com")//book
 where $b/publisher = "Addison-Wesley"
and $b/@year > 1991
                                                </livre>
 return < livre annee= "{$b/@year}">
          {$b/title}
        </livre>
                                                </livre>
                                               </bib>
</bib>
```

```
vre annee= "1994">
  <title> TCP/IP Illustrated </title>
vre annee= "1992">
  <title>Advanced Programming in Unix</title>
```

Exemple (2)

Liste de toutes les paires (title, last), chaque paire étant contenue dans un élément result.

```
<results>
 <result>
  <title>TCP/IP Illustrated</title>
  <last>Stevens/last>
 </result>
 <result>
  <title>Advanced Programming in Unix </title>
  <last>Stevens/last>
 </result>
 <result>
  <title>Data on the Web</title>
  <last>Abiteboul
 </result>
<result>
  <title>Data on the Web</title>
  <last>Buneman/last>
 </result>
</results>
```

Exemple (3)

Une entré par livre avec le titre et tous les noms d'auteurs:

```
<results>
 <result>
  <title>TCP/IP Illustrated</title>
  <last>Stevens/last>
 </result>
 <result>
  <title>Advanced Programming in Unix </title>
  <last>Stevens/last>
 </result>
 <result>
  <title>Data on the Web</title>
  <last>Abiteboul/last>
  <last>Buneman/last>
  <last>Suciu</last>
 </result>
```

distinct-values(): élimination de doublons par valeur

Le document carnet.xml est un carnet (c) de personnes (p).

Chaque personne a un nom (n), un age (a) et une ville de résidence (v).

```
<?xml version="1.0">
<c>

</c>
```

```
distinct-values(//p/@a) retourne la sequence de valeurs de l'attribute @a sans doublons: (60, 30, 50)
```

Réponse

```
<resultat>
<age a="60">
</age>
<age a="30">
</age>
<age a="50">
</age>
</resultat>
```



```
<?xml version="1.0">
<c>

        </c>
```

Réponse

```
<p1 n="paul"/>
<p2 n="paul"/>
</proche>,
<p1 n="paul"/>
<p2 n="martin"/>
</proche>,
<p1 n="paul"/>
<p2 n="paul"/>
</proche>, ...
```

Que fait cette requête ? Que renvoie-t-elle ?

Réponse

<resultat>

```
  </resultat>
```

La requête renvoie la personne la plus âgée de chaque ville.

Jointure et élimination de doublons

Pour chaque auteur, la liste de ses livres.

```
<results>
{
    for $v in distinct-values(//author),
        $a in /descendant::author[.=$v][1]
    return
        <author>
            {$a/last,
                for $b in //book where $b/author = $a
                return $b/title
            }
            </author>
}
</results>
```

```
<results>
 <author>
  <last>Stevens</last>
  <title>TCP/IP Illustrated</title>
  <title>Advanced Programming in Unix/title>
 </author>
 <author>
  <last>Abiteboul
  <title>Data on the Web</title>
  <title>Database theory</title>
 </author>
 <author>
  <last>Buneman</last>
  <title>Data on the Web</title>
 </author>
</results>
```

Conclusion

XML: structure d'arbre

navigation grâce à XPath

caractérisation des sous-arbres grâce aux axes

Requêtes:

travaillent sur les sous-arbres construits

génèrent un sous-arbre extrait ou calculé

XQuery:

langage très puissant, comprenant toutes les fonctionnalités de SQL

Liens

www.w3.org/TR/xquery

www.w3.org/TR/xquery-requirements

www.w3.org/TR/xquery-use-cases

http://www-db.research.bell-labs.com/user/simeon/xquery.ps